

# Apostila de Regressão Linear Múltipla

Fundamentos Teóricos, Fórmulas e Interpretação Prática

Da Regressão Simples à Múltipla

Teoria + Exemplos Resolvidos

**Objetivo desta apostila:** construir, do zero, o entendimento conceitual completo por trás da Regressão Linear — começando pela regressão simples (uma variável), evoluindo para a múltipla (várias variáveis), e conectando cada conceito às métricas e suposições que você já vem praticando nos seus projetos.

Esta apostila complementa (não substitui) o **Guia de Regressão Linear Múltipla — Passo a Passo** que já construímos: lá está o "como fazer" em código; aqui está o "por que funciona assim" na teoria.

Preparado para Daiane · MBA Data Science, AI & Analytics · USP ESALQ

# Sumário

---

## Parte I — Fundamentos da Regressão

- 1. O que é Regressão?
- 2. Variável Dependente e Variável Independente
- 3. Correlação: o que ela representa (e o que não representa)
- 4. Tipos de Modelos de Regressão

## Parte II — Regressão Linear Simples

- 5. A Equação da Reta:  $y = a + bx$
- 6. Bias (a) e Inclinação (b) — o que o modelo realmente aprende
- 7. Resolvendo uma Regressão com Dois Pontos (exemplo manual)
- 8. O Método dos Mínimos Quadrados

## Parte III — Avaliando o Modelo

- 9. Erro Padrão da Estimativa
- 10. Coeficiente de Determinação ( $R^2$ )
- 11. Decompondo a Variância: SST, SQR e SQE
- 12. MAE, MSE e RMSE

## Parte IV — Da Regressão Simples à Múltipla

- 13. Por que "múltipla"? Generalizando a equação
- 14. Interpretando os Coeficientes na Regressão Múltipla
- 15.  $R^2$  vs.  $R^2$  Ajustado

## Parte V — As Suposições da Regressão Linear

- 16. As 5 Suposições Fundamentais
- 17. O que acontece quando uma suposição é violada

## Parte VI — Consolidando o Conhecimento

- 18. Exemplo Resolvido de Ponta a Ponta
- 19. Glossário de Termos
- 20. Mapa Mental Final

# Parte I — Fundamentos da Regressão

Antes da matemática, o conceito

## 1. O que é Regressão?

Em diversas áreas — medicina, biologia, indústria, finanças, engenharia — existe um interesse comum: entender se duas ou mais variáveis estão relacionadas de alguma forma, e usar essa relação para **prever** algo. A regressão é a ferramenta estatística que formaliza matematicamente essa relação.

**Explicação simples:** imagine que você quer prever o preço de uma casa a partir do seu tamanho. Você já viu dezenas de casas sendo vendidas e sabe, mais ou menos, que "casa maior custa mais". A regressão pega esse "mais ou menos" e transforma numa equação matemática exata: dado um tamanho, ela calcula um preço estimado. Isso funciona porque preço e tamanho estão relacionados de forma aproximadamente **linear** — por isso, regressão *linear*.

**Pergunta para fixar:** qual é a diferença entre "descrever uma relação entre variáveis" e "prever um valor a partir dela"? (A regressão faz as duas coisas: primeiro aprende a relação com dados históricos, depois usa essa relação para prever casos novos.)

## 2. Variável Dependente e Variável Independente

**Explicação simples:** a **variável dependente (y)** é o que você quer prever — ela "depende" do resto. A **variável independente (x)** é o que você usa para prever — ela existe por conta própria e "explica" a variação de y.

Exemplo clássico: a temperatura (x, independente) influencia o número de sorvetes vendidos (y, dependente). A relação só funciona numa direção: temperatura → vendas de sorvete, nunca o contrário.

**variável independente (x) → variável dependente (y)**

**Aplicação em Regressão Múltipla:** a mesma lógica vale quando há várias variáveis independentes ao mesmo tempo (x<sub>1</sub>, x<sub>2</sub>, x<sub>3</sub>...) explicando uma única variável dependente (y). É exatamente esse o salto que faremos na Parte IV.

## 3. Correlação: o que ela representa (e o que não representa)

**Explicação simples:** correlação mede se duas variáveis "se movem juntas". Se uma sobe quando a outra sobe, a correlação é **positiva** (ex: temperatura e vendas de sorvete). Se uma sobe quando a outra desce, a correlação é **negativa** (ex: preço de um item e sua demanda).

**Correlação não implica causalidade!** A temperatura influencia as vendas de sorvete, mas as vendas de sorvete não influenciam a temperatura — mesmo que ambas estejam correlacionadas. A regressão usa a relação estatística entre variáveis para prever uma a partir da outra, mas isso **não prova** que uma causa a outra. Duas variáveis podem estar correlacionadas por coincidência, ou por dependerem de uma terceira variável em comum (ex: sazonalidade).

## 4. Tipos de Modelos de Regressão

| Tipo                                 | Quando usar                                                                    |
|--------------------------------------|--------------------------------------------------------------------------------|
| Regressão Linear Simples             | Uma variável independente prevendo uma variável dependente contínua            |
| Regressão Linear Múltipla            | Duas ou mais variáveis independentes prevendo uma variável dependente contínua |
| Regressão Logística                  | Variável dependente categórica (ex: sim/não), apesar do nome "regressão"       |
| Regressão Polinomial                 | Relação entre x e y é curva, não uma linha reta                                |
| Regressão Ridge / Lasso / ElasticNet | Variações da regressão linear com regularização, para controlar overfitting    |

**O que realmente importa:** todos esses modelos compartilham a mesma lógica-base (variáveis explicando uma resposta) — o que muda é a forma da relação (linear, curva) e o tipo da variável prevista (contínua ou categórica).

## Parte II — Regressão Linear Simples

A base matemática antes de generalizar para várias variáveis

### 5. A Equação da Reta: $y = a + bx$

$$y = a + b \cdot x$$

- **y** — variável dependente (o que queremos prever)
- **x** — variável independente
- **a** — termo de viés (bias / intercepto)
- **b** — inclinação (slope / peso atribuído a x)

**Explicação simples:** essa é literalmente a equação de uma reta que você já viu na escola ( $y = mx + b$ , só com letras trocadas). A regressão linear simples nada mais é do que **encontrar a melhor reta possível** que passa pelo meio dos seus dados.

### 6. Bias (a) e Inclinação (b) — o que o modelo realmente aprende

**Exemplo:** queremos estimar o peso de um bebê pela idade em meses. O bebê nasce com 3 kg e ganha 0,75 kg por mês, de forma constante.

**O que é o bias (a)?** é o valor de y quando todas as variáveis independentes valem zero. Aqui,  $a = 3$  — o peso do bebê ao nascer (mês 0).

**O que é a inclinação (b)?** é o quanto y muda para cada unidade que x aumenta. Aqui,  $b = 0,75$  — a cada mês, o bebê ganha 0,75 kg.

$$b = (\text{diferença nas coordenadas y}) / (\text{diferença nas coordenadas x})$$

**Pergunta para fixar:** se um segundo bebê nascesse com 3,5 kg e ganhasse 0,5 kg por mês, quais seriam os valores de a e b para esse bebê? ( $a = 3,5$ ;  $b = 0,5$ )

### 7. Resolvendo uma Regressão com Dois Pontos (exemplo manual)

Imagine um conjunto de dados com apenas 2 pontos: no mês 0, o peso é 3,44 kg; no mês 1, o peso é 4,39 kg. Vamos encontrar a e b manualmente — exatamente como o modelo faria internamente.

$$\begin{aligned} \text{Mês 0: } 3,44 &= a + b \cdot (0) \rightarrow a = 3,44 \\ \text{Mês 1: } 4,39 &= a + b \cdot (1) \rightarrow 4,39 = 3,44 + b \rightarrow b = 0,95 \end{aligned}$$

**O que aconteceu aqui?** essas duas linhas de cálculo são o treinamento do modelo. "Treinar um modelo de regressão linear" significa exatamente isto: encontrar os valores de a e b que se encaixam nos dados observados.

**Limitação deste método com 2 pontos:** com apenas 2 pontos, sempre existe uma reta que passa exatamente por ambos — erro zero. Mas dados reais têm dezenas, centenas ou milhares de pontos, que raramente estão perfeitamente alinhados. Por isso, precisamos de um método mais geral: os **mínimos quadrados** (próximo capítulo).

### 8. O Método dos Mínimos Quadrados

**Explicação simples:** em vez de usar só 2 pontos, o método dos mínimos quadrados usa **todos os pontos** dos dados para encontrar a reta que minimiza o "erro total" entre a reta e cada ponto observado.

**Por que elevar o erro ao quadrado, e não usar o erro puro?** Se somássemos os erros diretamente, um erro de +5 em um ponto cancelaria um erro de -5 em outro, dando a falsa impressão de erro total zero. Ao elevar ao quadrado:

- Todo erro vira positivo — não há cancelamento entre superprevisão e subprevisão.
- Superprever em 5% é tratado como igualmente ruim que subprever em 5%.
- Erros maiores são penalizados desproporcionalmente mais — o que incentiva o modelo a evitar grandes desvios.

**Exemplo numérico:** um erro de +5 em 3 pontos e -5 em outros 3 pontos soma zero em erro "puro" — parece perfeito, mas não é. Elevando ao quadrado:  $6 \times 5^2 = 150$  de erro total — um número que reflete de verdade o quanto o modelo errou.

**O resultado:** a reta encontrada por este método é chamada de **reta de regressão** — a melhor aproximação linear possível para a nuvem de pontos dos seus dados. Ela nunca é perfeita, apenas a mais próxima possível de todos os pontos ao mesmo tempo.

# Parte III — Avaliando o Modelo

Depois de treinar a reta, como saber se ela é boa?

## 9. Erro Padrão da Estimativa

**Explicação simples:** é a distância média entre os pontos reais e a linha de regressão, medida na mesma unidade da variável dependente (ex: kg, R\$, anos). Quanto menor, melhor — significa que, em média, os pontos "caem" mais perto da reta.

**O que realmente importa:** o erro padrão dá uma medida **absoluta** (nas unidades reais dos dados); o  $R^2$  (próximo capítulo) dá uma medida **relativa** (percentual). Um bom relatório estatístico sempre reporta os dois juntos.

## 10. Coeficiente de Determinação ( $R^2$ )

**Explicação simples:** o  $R^2$  responde à pergunta: "que porcentagem da variação de y eu consigo explicar usando x?" Varia de 0 a 1 (ou 0% a 100%). Um  $R^2$  de 0,80 significa que 80% da variação da variável dependente é explicada pelo modelo — os outros 20% ficam por conta de fatores que o modelo não capturou.

$$R^2 = (\text{coeficiente de correlação})^2$$

|                  | Coeficiente de Correlação (r) | Coeficiente de Determinação ( $R^2$ ) |
|------------------|-------------------------------|---------------------------------------|
| Faixa de valores | -1 a +1                       | 0 a 1 (sempre positivo)               |
| O que mede       | Força e direção da relação    | % da variância explicada pelo modelo  |

**Armadilha comum:** um  $R^2$  alto **não prova** que uma variável explicativa é estatisticamente significativa, nem que existe relação de causa e efeito.  $R^2$  mede ajuste, não significância nem causalidade.

## 11. Decompondo a Variância: SST, SQR e SQE

Para entender de onde vem o  $R^2$ , é útil decompor a variação total da variável y em duas partes:

| Sigla        | Nome completo                   | O que representa                                                  |
|--------------|---------------------------------|-------------------------------------------------------------------|
| SST (ou STQ) | Soma Total dos Quadrados        | Toda a variação de y em torno da própria média                    |
| SQR          | Soma dos Quadrados de Regressão | Parte da variação de y explicada pelas variáveis X do modelo      |
| SQE (ou SSE) | Soma dos Quadrados dos Resíduos | Parte da variação de y que o modelo NÃO conseguiu explicar (erro) |

$$SST = SQR + SQE$$

$$R^2 = SQR / SST$$

**Explicação simples:** pense na variação total de y como um bolo inteiro (SST). O modelo consegue "explicar" uma fatia desse bolo (SQR) — o resto é o que sobra sem explicação (SQE, os resíduos). O  $R^2$  é simplesmente: *que fração do bolo o modelo conseguiu explicar.*

## 12. MAE, MSE e RMSE

| Métrica                              | O que faz                                            | Característica                                                              |
|--------------------------------------|------------------------------------------------------|-----------------------------------------------------------------------------|
| MAE — Erro Médio Absoluto            | Média das diferenças absolutas entre previsto e real | Todos os erros pesam igual, na escala original                              |
| MSE — Erro Quadrático Médio          | Média dos quadrados das diferenças                   | Penaliza mais os erros grandes; unidade fica "ao quadrado"                  |
| RMSE — Raiz do Erro Quadrático Médio | Raiz quadrada do MSE                                 | Volta à escala original da variável, mantendo a penalização a erros grandes |

**Exemplo:** um modelo que prevê preços de casas com MAE = 10.000 erra, em média, R\$ 10.000 para mais ou para menos. Se o MSE for 25 (numa escala menor, hipotética), significa que a média dos erros ao quadrado é 25 — não é diretamente comparável ao MAE por causa do quadrado, por isso o RMSE (raiz do MSE) é preferido quando se quer comparar na mesma unidade da variável original.

**O que realmente importa:** MAE é mais fácil de interpretar e menos sensível a outliers; MSE/RMSE penalizam mais fortemente erros grandes — use MSE/RMSE quando errar muito em poucos casos for particularmente indesejável.

# Parte IV — Da Regressão Simples à Múltipla

O salto conceitual que você está estudando agora

## 13. Por que "múltipla"? Generalizando a equação

Na prática, raramente uma única variável explica bem algo tão complexo quanto o preço de uma casa, a expectativa de vida de uma população, ou o risco de crédito de um cliente. A **Regressão Linear Múltipla** generaliza a equação simples para incluir várias variáveis independentes ao mesmo tempo:

$$y = a + b_1x_1 + b_2x_2 + b_3x_3 + \dots + b_nx_n + \epsilon$$

- a** — intercepto (o valor de y quando todas as variáveis x valem zero)
- b<sub>1</sub>, b<sub>2</sub>, ..., b<sub>n</sub>** — coeficientes de cada variável independente
- x<sub>1</sub>, x<sub>2</sub>, ..., x<sub>n</sub>** — as variáveis independentes (preditoras)
- ε** — termo de erro (o que o modelo não consegue explicar)

**Explicação simples:** em vez de uma reta em um plano 2D (y por x), a regressão múltipla constrói um "plano" (ou hiperplano, quando há mais de 2 variáveis) num espaço com mais dimensões. A lógica de mínimos quadrados continua exatamente a mesma — só que agora o modelo procura os melhores coeficientes para **várias** variáveis simultaneamente, e não apenas uma.

## 14. Interpretando os Coeficientes na Regressão Múltipla

**Explicação simples:** cada coeficiente b<sub>i</sub> representa o quanto y muda para cada unidade de aumento em x<sub>i</sub>, **mantendo todas as outras variáveis constantes** ("ceteris paribus"). Essa condição — "todo o resto constante" — é o que diferencia a interpretação de um coeficiente múltiplo da inclinação simples do Capítulo 6.

**Exemplo prático (do seu projeto de expectativa de vida):** se o coeficiente de *school* (anos de escolaridade) for +0,9, isso significa: "mantendo hiv, mortalidade adulta e as demais variáveis constantes, cada ano a mais de escolaridade está associado a um aumento de 0,9 ano na expectativa de vida prevista."

**Armadilha comum:** interpretar o coeficiente como se as outras variáveis não existissem. Em regressão múltipla, o efeito de uma variável isolada só faz sentido quando comparado com as demais mantidas fixas — ignorar isso é uma das causas mais comuns de conclusões erradas.

## 15. R² vs. R² Ajustado

**Explicação simples:** um problema do R² comum é que ele **sempre aumenta** (ou no mínimo, nunca diminui) quando você adiciona mais variáveis ao modelo — mesmo que essas variáveis sejam irrelevantes! O R² Ajustado corrige isso, penalizando o modelo por adicionar variáveis que não contribuem de fato.

|                                      | R²                             | R² Ajustado                                    |
|--------------------------------------|--------------------------------|------------------------------------------------|
| Comportamento ao adicionar variáveis | Sempre aumenta (ou mantém)     | Só aumenta se a nova variável realmente ajudar |
| Uso recomendado                      | Regressão simples (1 variável) | Regressão múltipla (várias variáveis)          |

**O que realmente importa:** ao comparar modelos com diferentes quantidades de variáveis (como fizemos com as versões V1 a V5 no guia prático), prefira sempre o R² Ajustado — ele é mais honesto sobre a real contribuição de cada variável adicional.

# Parte V — As Suposições da Regressão Linear

O que precisa ser verdade para os resultados serem confiáveis

## 16. As 5 Suposições Fundamentais

| Suposição                      | O que significa                                                        | Como checar                                          |
|--------------------------------|------------------------------------------------------------------------|------------------------------------------------------|
| Linearidade                    | A relação entre X e Y é aproximadamente linear                         | Pairplot / gráfico de dispersão                      |
| Independência dos erros        | Os resíduos de uma observação não influenciam os de outra              | Teste de Durbin-Watson (dados temporais/sequenciais) |
| Homoscedasticidade             | A variância dos erros é constante em todos os níveis de X              | Gráfico resíduos vs. valores previstos               |
| Normalidade dos resíduos       | Os erros seguem uma distribuição aproximadamente normal                | Gráfico Q-Q dos resíduos                             |
| Ausência de multicolinearidade | As variáveis independentes não são fortemente correlacionadas entre si | Matriz de correlação / VIF                           |

**Explicação simples:** essas suposições são as "regras do jogo" da regressão linear. Quando todas são atendidas, os coeficientes estimados e os testes de significância (valores-p) são confiáveis. Quando uma é violada, os resultados ainda existem — mas podem enganar.

## 17. O que acontece quando uma suposição é violada

| Suposição violada        | Consequência prática                                                                             |
|--------------------------|--------------------------------------------------------------------------------------------------|
| Linearidade              | Modelo sistematicamente sub ou superestima em certas faixas de valores                           |
| Independência            | Erros-padrão dos coeficientes ficam subestimados — testes de significância enganosos             |
| Homoscedasticidade       | Previsões menos confiáveis em algumas faixas de valores do que em outras                         |
| Normalidade dos resíduos | Intervalos de confiança e testes de hipótese perdem precisão (mais crítico em amostras pequenas) |
| Multicolinearidade       | Coefficientes instáveis e difíceis de interpretar individualmente                                |

**Boa notícia:** nenhuma violação torna o modelo "inútil" automaticamente — mas cada uma exige uma resposta específica (transformação de variável, remoção de preditoras redundantes, uso de erros-padrão robustos, etc.), e ignorá-las silenciosamente é o erro mais comum em projetos de regressão.

## Parte VI — Consolidando o Conhecimento

*Juntando teoria e prática num único fio condutor*

### 18. Exemplo Resolvido de Ponta a Ponta

**Cenário:** queremos prever a expectativa de vida ( $y$ ) usando duas variáveis: mortalidade adulta ( $x_1$ ) e anos de escolaridade ( $x_2$ ).

1. **Definir a equação:**  $\text{expectativa\_vida} = a + b_1 \cdot \text{mortalidade\_adulta} + b_2 \cdot \text{escolaridade} + \epsilon$
2. **Treinar (mínimos quadrados):** o algoritmo encontra os valores de  $a$ ,  $b_1$  e  $b_2$  que minimizam a soma dos erros ao quadrado entre os valores previstos e os reais, usando todos os países da base.
3. **Interpretar os coeficientes:** suponha  $b_1 = -0,03$  e  $b_2 = +0,9$ . Isso significa: mantendo a escolaridade constante, cada unidade a mais de mortalidade adulta reduz a expectativa de vida prevista em 0,03 ano; mantendo a mortalidade constante, cada ano a mais de escolaridade aumenta a expectativa de vida prevista em 0,9 ano.
4. **Avaliar o ajuste:** calcular  $R^2$  (ou  $R^2$  Ajustado) para saber que fração da variação da expectativa de vida esse modelo de 2 variáveis já explica, e RMSE para saber o erro médio em anos.
5. **Checkar as suposições:** plotar resíduos vs. previstos (homoscedasticidade) e Q-Q plot (normalidade), confirmar ausência de multicolinearidade entre mortalidade e escolaridade.
6. **Usar para prever:** aplicar a equação a um país novo, informando seus valores de mortalidade e escolaridade, para obter a expectativa de vida estimada.

**Conecte com a prática:** esses 6 passos são exatamente o que você já executou no *Guia de Regressão Linear Múltipla — Passo a Passo*, só que aqui explicados na lógica matemática por trás de cada etapa de código.

### 19. Glossário de Termos

#### Variável dependente ( $y$ )

O que o modelo tenta prever.

#### Variável independente ( $x$ )

O que o modelo usa para prever  $y$ .

#### Bias / Intercepto ( $a$ )

Valor de  $y$  quando todas as variáveis  $x$  são zero.

#### Coefficiente / Inclinação ( $b$ )

Quanto  $y$  muda para cada unidade de mudança em  $x$  (mantendo as demais constantes, na regressão múltipla).

#### Resíduo (erro)

Diferença entre o valor real e o valor previsto pelo modelo.

#### Mínimos Quadrados

Método que encontra a reta/plano que minimiza a soma dos erros ao quadrado.

#### $R^2$ (Coeficiente de Determinação)

Percentual da variação de  $y$  explicado pelo modelo.

#### $R^2$ Ajustado

Versão do  $R^2$  que penaliza a adição de variáveis irrelevantes.

#### MAE / MSE / RMSE

Métricas de erro médio do modelo, cada uma com uma forma diferente de penalizar os erros.

#### Multicolinearidade

Alta correlação entre variáveis independentes, que compromete a estabilidade dos coeficientes.

#### Homoscedasticidade

Variância constante dos erros ao longo de todos os valores previstos.

## 20. Mapa Mental Final

1. **Conceito** → regressão é sobre usar variáveis conhecidas (x) para prever uma variável desconhecida (y), sem que isso implique causalidade.

2. **Simples** →  $y = a + bx$ . O treinamento é encontrar a e b que minimizam o erro quadrático total (mínimos quadrados).

3. **Avaliação** → erro padrão da estimativa (absoluto) e  $R^2$  (relativo) dizem o quão boa é a reta;  $SST = SQR + SQE$  explica de onde vem o  $R^2$ ; MAE/MSE/RMSE quantificam o erro de formas complementares.

4. **Múltipla** → generaliza para  $y = a + b_1x_1 + \dots + b_nx_n$ . Cada coeficiente é interpretado "mantendo as demais variáveis constantes". Use  $R^2$  Ajustado, não  $R^2$ , para comparar modelos com números diferentes de variáveis.

5. **Suposições** → linearidade, independência, homoscedasticidade, normalidade dos resíduos e ausência de multicolinearidade. Violações não invalidam o modelo automaticamente, mas exigem correções específicas.

6. **Prática** → tudo isso se conecta diretamente ao seu *Guia de Regressão Linear Múltipla — Passo a Passo*: da limpeza de dados ao diagnóstico de resíduos, cada etapa de código existe para garantir que essas suposições e métricas estejam sendo respeitadas.